

Dziś

AirSense Weather AI

Inteligentny system predykcji jakości powietrza i pogody

Sekwencyjny model LSTM · Streamlit · dane GIOŚ + Open-Meteo

Grupa 5

Jakub Moszyński · Damian Tomczyk · Nikol Olszewska · Łukasz Duss

• Plan prezentacji

1 Przegląd projektu i problem

2 Dane i wyzwania preprocessingu

3 Model AI i jego uzasadnienie

4 Wyniki, metryki i wizualizacje

5 Demo aplikacji

6 Wnioski i kierunki rozwoju



Zespół i podział pracy



Jakub Moszyński

Data Engineer

Integracja API GIOŚ i Open-Meteo, pobieranie i czyszczenie danych, przygotowanie sekwencji czasowych.



Damian Tomczyk

Data Analyst

Analiza eksploracyjna (EDA), dashboard Streamlit, wizualizacje trendów w Plotly, linia „Dziś”.



Nikol Olszewska

Deep Learning Engineer

Architektura LSTM Seq2Seq, Dropout, skalowanie danych, dynamiczna liczba cech.



Łukasz Duss

ML Analyst / Project Manager

Integracja aplikacji, podział 80/10/10, ewaluacja MAE/MSE/RMSE/R², rejestr modeli, Session State.

1

Problem: jakość powietrza i prognoza

- Polska zмага się z wysokim poziomem smogu (PM10, PM2.5, NO2), szczególnie w sezonie grzewczym.
- Decyzje (aktywność na zewnątrz, ostrzeżenia) wymagają prognozy na kolejne dni — nie tylko bieżącego odczytu.
- Dane są rozproszone: pogoda w jednym źródle, zanieczyszczenia w drugim.
- Potrzebny jest system, który łączy te źródła i automatycznie prognozuje kolejne dni.

Nasz cel

Prototyp łączący realne dane pogodowe i środowiskowe i prognozujący je krótkoterminowo (godzinowo) za pomocą sieci LSTM.

5

stacji pomiarowych

+1-24 9


godziny prognozy

9

śledzonych cech

1

Pełny pipeline Machine Learning



Od pobrania danych z publicznych API, przez czyszczenie i sekwencje czasowe, po model LSTM, ewaluację i predykcję — wszystko w jednej aplikacji Streamlit. Projekt obejmuje pełny cykl ML (prototyp klasy MLOps).

2

Skąd pochodzą dane



Open-Meteo — pogoda

- Temperatura, wilgotność, prędkość wiatru
- Dane godzinowe (~720 punktów na 30 dni)
- forecast_days=1 — bez godzin „w przyszłość”



GIOŚ API v1 — zanieczyszczenia

- PM10, PM2.5, NO2, NOx, O3, NO — zależnie od stacji
- Nagłówki HTTP imitujące przeglądarkę (omijają blokady)
- Uwaga: API daje tylko ~3 dni historii godzinowej

5 stacji pomiarowych: Zabrze · Warszawa · Kraków · Gdańsk · Wrocław

2

Wyzwania w przygotowaniu danych

Braki w pomiarach

Interpolacja liniowa w obie strony (`limit_direction='both'`).

Błędne piki czujników

Przycinanie do 1. i 99. percentyla (winsoryzacja).

Różna liczba sensorów

Dynamiczna liczba cech wyznaczana per stacja (`CURRENT_FEATURES`).

Blokady API GIOŚ

Nagłówki HTTP (User-Agent, Referer) + obsługa błędów.

Dni „w przyszłość” z czujek

`forecast_days=1` + obcięcie do dziś; pionowa linia „Dziś” na wykresie.

3

Model: LSTM Sequence-to-Sequence



- **LSTM** dobrze modeluje zależności w szeregach czasowych (pamięć krótkiej historii).
- **Seq2Seq**: z okna 48 h przewiduje kolejne godziny naprzód jednocześnie.
- **Wielowymiarowość**: wszystkie cechy (pogoda + zanieczyszczenia) na wejściu i wyjściu.
- **Dropout 0.2**: ogranicza przeuczenie przy stosunkowo małym zbiorze.
- **Dynamiczne wejście**: kształt dopasowany do liczby sensorów danej stacji.

3

Trening i konfiguracja modelu

Podział 80 / 10 / 10

trening / walidacja / test — chronologicznie, bez tasowania.

Okno 48 h → horyzont +1-24 h

model godzinowy; ~700 punktów na 30 dni.

2× LSTM(64) + Dropout

Dense + Reshape na wyjściu sekwencyjnym.

Adam · MSE · early stopping

MinMaxScaler; parametry skalera zapisane do predykcji.

4 Wyniki — realne metryki (dane godzinowe)

13%

błąd wzgl. wilgotności (najlepszy)

~3 °C


średni błąd temperatury (MAE)

≈ 0

R^2 — poziom baseline'u


Metryki realne, w jednostkach rzeczywistych. Model łapie krótkoterminowy sygnał (wilgotność, pogoda).

R^2 bliskie 0 i niestabilne — mały zbiór testowy i tylko ~3 dni danych GIOŚ.




4

Wizualizacje w aplikacji



EDA: dane godzinowe (cykl dobowy) + 24-godzinna średnia krocząca + pionowa linia „Dziś”.



Predykcja vs rzeczywistość (zbiór testowy, +1 h): model śledzi ogólny kształt, ale z wyraźnymi błędami.

5 Demo aplikacji (Streamlit)

1

Zakładka 1

EDA i Trendy

Wybór stacji i parametru; wykres odczytów + średnia krocząca 24h + linia „Dziś”.

2

Zakładka 2

Model LSTM

Konfiguracja i trening modelu; podział 80/10/10; pasek postępu epok na żywo.

3

Zakładka 3

Predykcja i Ewaluacja

Metryki, edytowalna macierz wejściowa, interaktywny wykres prognozy.

Demo na żywo: `streamlit run app.py` (plan awaryjny: zrzuty ekranu / nagranie)

6 Wnioski

- **Działający prototyp klasy MLOps:** pełny pipeline od publicznych API po predykcję w aplikacji webowej.
- **Realne dane godzinowe:** GIOŚ (zanieczyszczenia) + Open-Meteo (pogoda), czyszczone i łączone automatycznie.
- **Krótkoterminowo model łapie sygnał pogodowy** (wilgotność, temperatura) — ale to wciąż prototyp, nie model produkcyjny.
- **Główne ograniczenie:** tylko ~3 dni danych GIOŚ i mały zbiór testowy → R^2 bliskie 0 i niestabilne.
- **Uczciwa ewaluacja:** metryki w jednostkach rzeczywistych, w rozbiciu na cechy, na wydzielonym zbiorze testowym.

6

Kierunki dalszego rozwoju

● Dłuższa historia danych niż 30 dni

● Więcej miast + automatyczne wykrywanie stacji

● Porównanie z GRU, Prophet, XGBoost, Transformerami

● Automatyczny, cykliczny re-trening modeli

● Zapis historii predykcji w bazie danych

● Rozbudowany rejestr modeli z porównaniem metryk



Dziękujemy za uwagę

Pytania?

AirSense Weather AI · Grupa 5

```
streamlit run app.py
```